# LAPORAN TUGAS BESAR
# SAINS DATA REKAYASA
# TF2203
# REGU 211


**Disusun Oleh:**

**Yusuf Lamuri (13321050)**
**Kevin Kristian Silaen(13323036)**
**Rio Haris Ewaldo Bukit (13323050)**
**Zahran Khairan Azmi(13323092)**

**PROGRAM STUDI TEKNIK FISIKA**
**FAKULTAS TEKNOLOGI INDUSTRI**
**INSTITUT TEKNOLOGI BANDUNG**

**2025**

# DAFTAR ISI

**DAFTAR ISI** 2
**BAB I** 3
**PENDAHULUAN** 3
1.1. Latar Belakang 3
1.2. Rumusan Masalah 4
1.3. Tujuan 4
**BAB II** 5
**METODE ACUAN** 5
2.1 Metode Random Forest Dalam Melakukan Regresi Supervised 5
2.2 Metode ANN Dalam Melakukan Regresi Supervised 6
**BAB III** 9
**METODE KEMBANGAN** 9
3.1 Metode LSTM Dalam Melakukan Regresi Supervised 9
3.2 Metode GRU Dalam Melakukan Regresi Supervised 10
**BAB IV** 11
**ANALISIS** 11
4.1. Analisis perbandingan antara metode ANN dengan Metode LSTM 11
4.1.1 Perbandingan Fungsional 11
4.1.2 Perbandingan Kinerja 12
4.1.3 Perbandingan Kecepatan Proses 12
4.2 Analisis perbandingan antara metode ANN dengan Metode GRU 12
4.2.1 Perbandingan Fungsional 12
4.2.2 Perbandingan Kinerja 12
4.2.3 Perbandingan Kecepatan Proses 12
4.3 Analisis perbandingan antara metode Random Forest dengan Metode LSTM 12
4.3.1 Perbandingan Fungsional 12
4.3.2 Perbandingan Kinerja 13
4.3.3 Perbandingan Kecepatan Proses 13
4.4 Analisis perbandingan antara metode Random Forest dengan Metode GRU 14
4.4.1 Perbandingan Fungsional 14
4.4.2 Perbandingan Kinerja 14
4.4.3 Perbandingan Kecepatan Proses 14
**BAB V** 15
**PENUTUP** 15
5.1. Simpulan 15
5.2. Saran 16
**DAFTAR PUSTAKA** 16
**KERJASAMA** 17

**LAMPIRAN.....17**

# BAB I

# PENDAHULUAN

## 1.1. Latar Belakang

Kebutuhan akan energi listrik yang stabil dan efisien merupakan pilar utama dalam mendukung aktivitas industri dan masyarakat modern. Salah satu teknologi pembangkit listrik yang paling efisien saat ini adalah Pembangkit Listrik Tenaga Gas dan Uap (PLTGU) atau Combined Cycle Power Plant (CCPP). Sistem CCPP bekerja dengan mengintegrasikan turbin gas dan turbin uap untuk menghasilkan listrik, sehingga mampu mencapai efisiensi termal yang tinggi.

Keluaran daya listrik bersih per jam (PE) dari sebuah CCPP sangat dipengaruhi oleh kondisi lingkungan sekitar. Mirip dengan bagaimana kecepatan angin menjadi variabel krusial untuk menentukan output turbin angin, pada CCPP, variabel seperti suhu ambien (AT), tekanan ambien (AP), kelembapan relatif (RH), dan vakum pada pembuangan uap (V) secara langsung mempengaruhi efisiensi operasional.Fluktuasi variabel-variabel ini menyebabkan output daya pembangkit juga berfluktuasi setiap jamnya. Oleh karena itu, kemampuan untuk melakukan prediksi (**regresi supervised**) keluaran daya secara akurat menjadi sangat penting untuk optimasi operasional, penjadwalan pemeliharaan, dan manajemen pasokan listrik ke jaringan (grid).

Untuk mengatasi tantangan ini, berbagai metode machine learning dapat diterapkan. Kajian ini akan membandingkan kinerja model-model dari arsitektur yang berbeda. Sebagai metode acuan, akan digunakan Random Forest, yang merupakan model ensemble klasik, dan Artificial Neural Network (ANN), sebagai model dasar jaringan saraf tiruan. Sebagai metode kembangan, akan dieksplorasi arsitektur Recurrent Neural Network (RNN) yaitu Long Short-Term Memory (LSTM) dan Gated Recurrent Unit (GRU), yang dirancang khusus untuk menangkap pola dari data sekuensial atau data deret waktu seperti data pengukuran per jam pada kasus ini. Data yang digunakan berasal dari dataset Combined Cycle Power Plant yang tersedia

di UCI Machine Learning Repository, yang berisi 9568 sampel data pengukuran per jam. Dataset yang digunakan dalam studi ini bersumber dari repositori UCI Machine Learning, secara spesifik *Combined Cycle Power Plant Data Set* (Kaya, Tüfekci, & Gürgen, 2012), yang mencakup 9.568 titik data hasil pengukuran per jam (https://archive.ics.uci.edu/dataset/294/combined+cycle+power+plant) .

## 1.2. Rumusan Masalah

1. Bagaimana perbandingan akurasi dan efisiensi antara metode acuan ANN dengan metode kembangan berbasis RNN LSTM dalam menangani kasus regresi output daya atau prediksi output daya (regresi)?
2. Bagaimana perbandingan akurasi dan efisiensi antara metode acuan ANN dengan metode kembangan berbasis RNN GRU dalam menangani kasus regresi output daya atau prediksi output daya (regresi)?
3. Bagaimana perbandingan akurasi dan efisiensi antara metode acuan Random Forest dengan metode kembangan berbasis RNN LSTM dalam menangani kasus regresi output daya atau prediksi output daya (regresi)?
4. Bagaimana perbandingan akurasi dan efisiensi antara metode acuan Random Forest dengan metode kembangan berbasis RNN GRU dalam menangani kasus regresi output daya atau prediksi output daya (regresi)?

## 1.3. Tujuan

1. Menganalisis dan membandingkan secara kuantitatif kinerja antara metode acuan ANN dan metode kembangan LSTM untuk menentukan arsitektur model yang paling unggul untuk studi kasus ini.

2. Menganalisis dan membandingkan secara kuantitatif kinerja antara metode acuan ANN dan metode kembangan GRU untuk menentukan arsitektur model yang paling unggul untuk studi kasus ini.
3. Menganalisis dan membandingkan secara kuantitatif kinerja antara metode acuan Random Forest dan metode kembangan LSTM untuk menentukan arsitektur model yang paling unggul untuk studi kasus ini.
4. Menganalisis dan membandingkan secara kuantitatif kinerja antara metode acuan Random Forest dan metode kembangan GRU untuk menentukan arsitektur model yang paling unggul untuk studi kasus ini.

# BAB II

# METODE ACUAN

## 2.1 Metode Random Forest Dalam Melakukan Regresi Supervised

Random Forest adalah sebuah metode *ensemble learning* yang sangat kuat dan serbaguna, yang diperkenalkan oleh Leo Breiman. Metode ini bekerja dengan menggabungkan sejumlah besar pohon keputusan (*decision trees*) untuk menghasilkan prediksi yang lebih akurat dan stabil dibandingkan dengan menggunakan satu pohon keputusan tunggal. Implementasi metode ini merujuk pada program kerja yang dipublikasikan oleh Alsisi (2023) (https://www.kaggle.com/code/mohamedalsisi/prediction-of-the-output-power-of-a-combined-cycle). Untuk tugas *forecasting* atau regresi, hasil akhir dari Random Forest adalah rata-rata dari prediksi yang diberikan oleh semua pohon di dalamnya.

Inti dari Random Forest adalah penggabungan dua ide utama: *bagging* dan seleksi fitur acak. Proses konstruksi model ini melibatkan langkah-langkah berikut:

1. Bootstrap Aggregating (Bagging): Dari total set data pelatihan, dibuat sejumlah sub-sampel data yang disebut *bootstrap sample*. Setiap *bootstrap sample* ini dibuat

dengan cara mengambil sampel secara acak dengan pengembalian (*sampling with replacement*) dari data asli. Artinya, beberapa data mungkin terpilih lebih dari satu kali, sementara yang lain mungkin tidak terpilih sama sekali. Setiap pohon keputusan dalam "hutan" (*forest*) kemudian dibangun hanya menggunakan satu *bootstrap sample* yang unik.

2. Seleksi Fitur Acak: Saat membangun setiap pohon keputusan, pada setiap simpul (*node*) atau titik pemisahan, model tidak mempertimbangkan semua fitur yang ada untuk mencari pemisahan terbaik. Sebaliknya, model hanya memilih subset acak dari total fitur yang tersedia. Dari subset fitur yang terbatas inilah model akan mencari fitur dan nilai terbaik untuk memisahkan data. Langkah ini adalah kunci yang membedakan Random Forest dari metode *bagging* biasa dan berfungsi untuk mengurangi korelasi antar pohon, sehingga meningkatkan kekuatan prediksi dari *ensemble* secara keseluruhan.

Proses di atas diulang untuk membangun ratusan atau bahkan ribuan pohon keputusan. Ketika akan melakukan prediksi pada data baru, setiap pohon dalam "hutan" akan memberikan prediksinya sendiri. Hasil akhir untuk tugas regresi (seperti *forecasting* keluaran daya) adalah nilai rata-rata dari semua prediksi pohon individu tersebut.

Random Forest memiliki beberapa keunggulan inheren yang membuatnya menjadi metode yang sangat andal:

- Estimasi Error Tanpa Validasi Silang (Out-of-Bag Error): Karena setiap pohon dibangun menggunakan *bootstrap sample*, ada sekitar sepertiga dari data asli yang tidak pernah digunakan dalam pembangunan pohon tersebut (disebut data *out-of-bag* atau OOB). Data OOB ini dapat berfungsi sebagai set data uji internal untuk setiap pohon. Dengan menghitung rata-rata kesalahan prediksi pada data OOB di seluruh hutan, kita mendapatkan estimasi error generalisasi yang akurat dan tidak bias, tanpa perlu memisahkan set data validasi secara manual.

- Pengukuran Kepentingan Variabel (Variable Importance): Model ini menyediakan metrik internal untuk mengukur seberapa penting setiap variabel atau fitur. Ini dilakukan dengan cara mengacak nilai-nilai dari satu variabel pada data OOB dan mengukur seberapa besar penurunan akurasi model. Semakin besar penurunan akurasi setelah suatu variabel diacak, semakin penting variabel tersebut.

Secara keseluruhan, Random Forest menawarkan pendekatan *forecasting* yang tidak hanya akurat tetapi juga stabil dan memberikan wawasan tambahan mengenai data melalui fitur-fitur internalnya.

### 2.2 Metode ANN Dalam Melakukan Regresi Supervised

Artificial Neural Network (ANN) atau Jaringan Saraf Tiruan adalah sebuah paradigma pemrosesan informasi yang terinspirasi oleh sistem saraf biologis. Implementasi ANN pada laporan ini mengacu pada kerangka kerja yang dipresentasikan oleh Karataş (2021) (https://www.kaggle.com/code/ibrahimkaratas/regression-for-combined-cycle-power-plant) . Metode ini sangat populer dalam bidang **regresi supervised** energi karena kemampuannya yang luar biasa dalam memodelkan hubungan yang sangat kompleks dan non-linear antara variabel input dan output.

Secara umum, arsitektur ANN yang digunakan untuk tugas prediksi terdiri dari tiga jenis lapisan utama:

1. **Lapisan Input (Input Layer)**: Pintu masuk data, di mana setiap neuron merepresentasikan satu variabel prediktor (AT, AP, RH, V).
2. **Lapisan Tersembunyi (Hidden Layers)**: Lapisan komputasi inti di mana jaringan menangkap pola-pola kompleks dari data.
3. **Lapisan Output (Output Layer)**: Menghasilkan hasil akhir prediksi. Untuk tugas regresi, lapisan ini biasanya terdiri dari satu neuron.

Menurut Teorema Aproksimasi Universal, ANN secara teoritis mampu memodelkan hubungan sekompleks apapun antara variabel input dan output. Kemampuan teoretis inilah yang membuat ANN sangat efektif untuk tugas praktis seperti **regresi supervised** di pembangkit listrik. Model ini dapat "belajar" hubungan termodinamika yang rumit dari data historis secara langsung.

ANN dilatih menggunakan algoritma propagasi balik atau backpropagation, di mana bobot koneksi antar neuron disesuaikan secara iteratif untuk meminimalkan kesalahan (error) antara nilai prediksi dan nilai aktual.

# BAB III

# METODE KEMBANGAN

## 3.1 Metode LSTM Dalam Melakukan Regresi Supervised

Long Short-Term Memory (LSTM) adalah arsitektur Recurrent Neural Network (RNN) canggih yang dirancang khusus untuk mengatasi masalah fundamental pada RNN standar, yaitu vanishing dan exploding gradient. Dengan kemampuannya untuk mempelajari dependensi jangka panjang, LSTM menjadi sangat efektif untuk tugas regresi supervised pada data deret waktu.

Kunci dari arsitektur LSTM adalah unit memorinya yang disebut sel (cell), yang memiliki kemampuan untuk menambah atau menghapus informasi dari keadaan sel (cell state) melalui struktur yang disebut gerbang (gates):

1. Forget Gate: Memutuskan informasi apa dari masa lalu yang perlu dibuang.
2. Input Gate: Menentukan informasi baru mana yang akan disimpan.
3. Output Gate: Menentukan output dari unit LSTM pada waktu tertentu.

Mekanisme gerbang yang canggih ini memungkinkan LSTM untuk secara selektif mengingat informasi penting selama periode waktu yang sangat panjang, menjadikannya pilihan yang sangat baik untuk memodelkan pola kompleks dalam data historis untuk melakukan prediksi.

### 3.2 Metode GRU Dalam Melakukan Regresi Supervised

Gated Recurrent Unit (GRU) adalah varian dari arsitektur RNN ber-gerbang yang diperkenalkan sebagai alternatif yang lebih sederhana dari LSTM. GRU memiliki tujuan yang sama dengan LSTM, yaitu menangkap dependensi jangka panjang, namun dengan desain arsitektur yang lebih sederhana dan parameter yang lebih sedikit, membuatnya lebih efisien secara komputasi.

Perbedaan utama antara GRU dan LSTM adalah bahwa GRU tidak memiliki cell state yang terpisah dari hidden state. Selain itu, GRU hanya menggunakan dua gerbang untuk mengatur aliran informasi:

1. Update Gate: Gabungan fungsi dari forget gate dan input gate pada LSTM.
2. Reset Gate: Memutuskan seberapa banyak informasi dari masa lalu yang harus dilupakan.

# BAB IV

# ANALISIS

## 4.1. Analisis perbandingan antara metode ANN dengan Metode LSTM

### 4.1.1 Perbandingan Fungsional

Jika dilihat dari segi fungsionalnya, ANN (seperti Multi-Layer Perceptron) dan LSTM sama-sama merupakan *Neural Network*, namun memiliki cara kerja yang fundamental berbeda.

- Konsep Kerja: ANN memproses setiap input data secara independen tanpa mempertimbangkan urutan. Model ini mengasumsikan bahwa setiap baris data tidak memiliki hubungan sekuensial dengan baris lainnya. Sebaliknya, LSTM dirancang khusus untuk memproses data sekuensial. Ia memiliki "memori" internal (*cell state*) yang memungkinkannya untuk menyimpan informasi dari langkah waktu sebelumnya dan menggunakannya untuk memengaruhi prediksi saat ini.
- Struktur dan Kompleksitas: Arsitektur LSTM jauh lebih kompleks daripada ANN standar karena memiliki mekanisme *gate* (gerbang) internal untuk mengatur aliran informasi. Hal ini membuat LSTM lebih unggul dalam menangkap pola dependensi waktu, namun juga lebih berat secara komputasi.
- Kasus Penggunaan: ANN cocok untuk masalah regresi atau klasifikasi pada data tabular di mana urutan tidak penting. LSTM unggul dalam tugas forecasting deret waktu atau pemrosesan bahasa alami, di mana konteks dari data sebelumnya sangat krusial.

### 4.1.2 Perbandingan Kinerja

Berdasarkan hasil eksekusi kode, diperoleh metrik kinerja sebagai berikut:

- **Metode Acuan (ANN):**
  - $R^2$: 0.9115
  - RMSE: 5.3487
  - MAE: 4.2850
  - MSE: 28.6091
- **Metode Kembangan (LSTM):**

- $R^2$: -0.0017
- RMSE: 17.1259
- MAE: 14.8721
- MSE: 293.2950

Hasil di atas menunjukkan adanya kesenjangan performa yang sangat besar antara kedua metode. Model ANN menunjukkan kinerja yang sangat baik dengan $R^2$ = 0.9115, yang berarti model mampu menjelaskan lebih dari 91% variabilitas data. Sebaliknya, model LSTM menghasilkan $R^2$ bernilai negatif (-0.0017).Temuan ini diperkuat oleh nilai galat LSTM yang sangat tinggi (misalnya RMSE = 17.1259 MW) jika dibandingkan dengan ANN (RMSE = 5.3487 MW). Pendekatan sekuensial sederhana dengan look back=1 tidak mampu menangkap pola yang relevan untuk memprediksi keluaran daya pada kasus ini.

#### 4.1.3 Perbandingan Kecepatan Proses

Aspek kecepatan proses membandingkan waktu yang dibutuhkan untuk melatih model (training) dan melakukan prediksi.

- **Waktu Training**:
  - ANN: 70.1036 detik
  - LSTM: 64.7328 detik
- **Waktu Prediksi**:
  - ANN: 0.1991 detik
  - LSTM: 0.6918 detik

Secara umum, diharapkan waktu training untuk LSTM akan lebih lama dibandingkan ANN.Namun model LSTM (64.73 detik) ternyata sedikit lebih cepat untuk dilatih dibandingkan ANN (70.10 detik). Salah satu kemungkinan penyebabnya adalah proses komputasi LSTM per-epoch lebih efisien untuk kasus ini. Akan tetapi, pada fase prediksi, keunggulan ANN terlihat jelas. Dengan waktu 0.1991 detik, ANN secara signifikan lebih cepat daripada LSTM (0.6918 detik) karena prosesnya yang bersifat langsung (*feedforward*) dan tidak berulang.

### 4.2 Analisis perbandingan antara metode ANN dengan Metode GRU

#### 4.2.1 Perbandingan Fungsional

Perbandingan fungsional antara ANN dan GRU sangat mirip dengan perbandingan ANN vs. LSTM, karena GRU adalah varian dari LSTM.

- Konsep Kerja: Sama seperti LSTM, GRU adalah jaringan *recurrent* yang memproses data secara sekuensial dan memiliki memori, sedangkan ANN memproses data secara statis dan independen.

- Struktur dan Kompleksitas: GRU memiliki arsitektur yang lebih sederhana daripada LSTM (hanya dua *gate* dan tidak ada *cell state* terpisah) tetapi tetap jauh lebih kompleks daripada ANN. Ini menjadikan GRU sebagai alternatif yang lebih efisien secara komputasi dibandingkan LSTM, namun tetap lebih berat daripada ANN.

- Kasus Penggunaan: ANN digunakan untuk data non-sekuensial. GRU, seperti LSTM, dirancang untuk data sekuensial dan seringkali memberikan kinerja yang sebanding dengan LSTM dengan waktu pelatihan yang lebih cepat.

### 4.2.2 Perbandingan Kinerja

- **Metode Acuan (ANN):**
  - $R^2$: 0.9115
  - RMSE: 5.3487
  - MAE: 4.2850
  - MSE: 28.6091

- **Metode Kembangan (GRU):**
  - $R^2$: -0.0025
  - RMSE: 17.1328
  - MAE: 14.9265
  - MSE: 293.5312

Sama halnya dengan LSTM, model GRU juga menunjukkan performa yang tidak baik. Hasil $R^2$ negatif (-0.0025) dan nilai RMSE yang tinggi (17.1328 MW) menegaskan bahwa pendekatan sekuensial dengan look_back=1 tidak cocok untuk dataset ini. Kinerjanya yang sangat mirip dengan LSTM disebabkan oleh kesamaan dasar arsitektur keduanya sebagai model RNN ber-gerbang. Jika dibandingkan dengan ANN, model GRU gagal menemukan pola yang berguna untuk membuat prediksi dari data historis yang diberikan.

### 4.2.3 Perbandingan Kecepatan Proses

- **Waktu Pelatihan**:
  - ANN: 70.1036 detik
  - GRU: 66.6013 detik
- **Waktu Prediksi**:
  - ANN:  0.1991 detik
  - GRU: 0.6890 detik

Sama seperti LSTM, waktu pelatihan GRU (66.60 detik) juga sedikit lebih cepat daripada ANN. Namun, pada fase prediksi, GRU (0.6890 detik) secara signifikan lebih lambat daripada ANN (0.1991 detik), ini menunjukkan bahwa komputasi rekuren memberikan beban tambahan saat inferensi.

## 4.3 Analisis perbandingan antara metode Random Forest dengan Metode LSTM

### 4.3.1 Perbandingan Fungsional

Perbandingan antara Random Forest dan LSTM adalah perbandingan antara model *ensemble* klasik dengan model *deep learning* sekuensial.

- Konsep Kerja: Random Forest membangun banyak pohon keputusan dan mengambil rata-rata atau suara mayoritas dari hasilnya. Model ini tidak memiliki pemahaman inheren tentang urutan atau waktu; ia hanya mencari pola dan interaksi fitur dalam data tabular. Di sisi lain, LSTM memproses data langkah demi langkah dan secara eksplisit memodelkan dependensi temporal.

- Penanganan Data: Random Forest bekerja langsung pada data tabular dan tidak sensitif terhadap skala fitur (tidak perlu normalisasi). Sebaliknya, LSTM memerlukan data untuk diubah menjadi format sekuensial [sampel, langkah waktu, fitur] dan kinerjanya sangat bergantung pada normalisasi data.

- Interpretasi: Random Forest menawarkan tingkat interpretasi yang lebih baik melalui feature importance, yang menunjukkan kontribusi setiap variabel input. LSTM sebagian besar berfungsi sebagai "kotak hitam" (*black box*) yang keputusannya sulit untuk diinterpretasikan.

### 4.3.2 Perbandingan Kinerja

Metodologi evaluasi untuk *Random Forest* melibatkan serangkaian eksperimen *hyperparameter tuning* untuk memastikan pemilihan model yang robust. Eksperimen ini mencakup:

1. **Optimisasi Jumlah Estimator** (n_estimators): Dilakukan pengujian performa $R^2$ terhadap variasi jumlah pohon dari 1 hingga 24. Hasilnya menunjukkan bahwa performa model meningkat secara signifikan seiring penambahan jumlah pohon dan mulai menunjukkan konvergensi (mendatar) setelah sekitar 15-20 pohon.

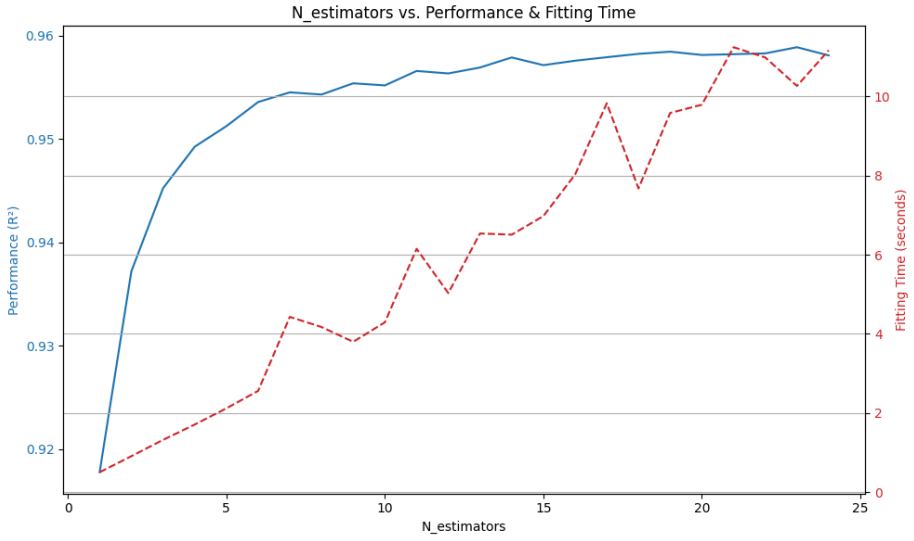


Gambar 4.3.2.1 Grafik analisis *hyperparameter*

2. **Pemilihan Kriteria Pemisahan (criterion)**: Perbandingan antara kriteria squared_error dan absolute_error menunjukkan bahwa **squared_error** tidak hanya menghasilkan performa $R^2$ yang sedikit lebih unggul (0.955 vs 0.953) tetapi juga secara drastis lebih efisien dalam hal waktu komputasi (3.48 detik vs 129.4 detik),

```
Random Forest regression with absolute_error criterion:
Fitting time:  129.407156188
Performance:  0.953633287237898
Random Forest regression with squared_error criterion:
Fitting time:  3.485286779999967
Performance:  0.9552466322022329
```

Gambar 4.3.2.2 Hasil Perbandingan

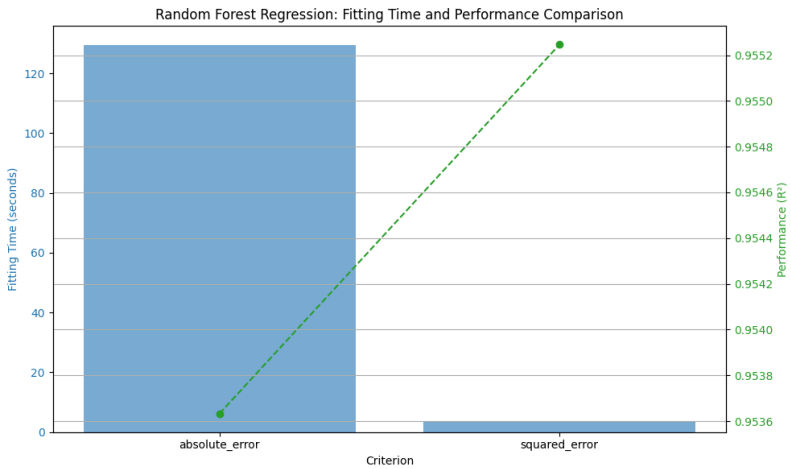


Gambar 4.3.2.3 Grafik batang pembanding

3. **Pemilihan Jumlah Fitur (max_features)**: Pengujian pada parameter max_features menunjukkan bahwa sqrt memberikan keseimbangan terbaik antara performa dan kecepatan.

```
Random Forest regression with max_features = sqrt:
Fitting time:  2.0650379400000247
Performance:  0.9568068097427203
Random Forest regression with max_features = sqrt(n):
Fitting time:  2.014743328999998
Performance:  0.9566574975886596
Random Forest regression with max_features = log2(n):
Fitting time:  2.6372328049999965
Performance:  0.9564178259046401
```

Gambar 4.3.2.4 Hasil Perbandingan max_features

Berdasarkan optimisasi tersebut, model final *Random Forest* dievaluasi menggunakan *10-fold cross-validation* untuk mendapatkan estimasi kinerja yang andal.

- **Metode Acuan (*Random Forest*)**:
    - $R^2$ (rata-rata cross-validation): 0.9537
    - RMSE: 3.6259
    - MAE: 2.5850
    - MSE: 13.3384

- **Metode Kembangan (LSTM)**:
    - $R^2$: -0.0017
    - RMSE: 17.1259
        -

Dari sisi kinerja, model Random Forest menunjukkan performa yang sangat tinggi dengan $R^2$ = 0.9537. Nilai ini secara signifikan lebih tinggi dibandingkan dengan model ANN (0.9022), mengindikasikan bahwa pendekatan ensemble lebih efektif untuk dataset tabular ini. Perbandingan lebih lanjut dengan LSTM akan bergantung pada hasil $R^2$ dari model sekuensial tersebut.

#### 4.3.3 Perbandingan Kecepatan Proses

- **Waktu Pelatihan**:
    - Random Forest (Final, cross-validated): 55.3496 detik
    - LSTM: 64.7328 detik
- **Waktu Prediksi**:
    - Random Forest: 0.0170 detik
    - LSTM: 0.6918 detik

Random Forest terbukti menjadi model yang paling efisien dalam pelatihan (55.35 detik). Pada fase prediksi, efisiensinya semakin membaik, di mana Random Forest (0.0170 detik) secara signifikan lebih cepat daripada LSTM (0.6918 detik).

## 4.4 Analisis perbandingan antara metode Random Forest dengan Metode GRU

### 4.4.1 Perbandingan Fungsional

Perbandingan ini juga menyoroti perbedaan antara pendekatan *ensemble* dan *deep learning* sekuensial.

- Konsep Kerja: Random Forest adalah kumpulan dari banyak model sederhana (pohon keputusan) yang tidak memiliki memori, sementara GRU adalah satu model kompleks yang memiliki memori internal untuk data sekuensial.

- Penanganan Data: Sama seperti perbandingannya dengan LSTM, Random Forest lebih mudah digunakan karena tidak memerlukan penskalaan atau pembentukan ulang data menjadi urutan. GRU memerlukan pra-pemrosesan data yang lebih intensif untuk performa yang optimal.

- Keseimbangan Kinerja dan Kompleksitas: Untuk data tabular murni di mana urutan waktu tidak terlalu penting, Random Forest seringkali memberikan kinerja yang sangat kuat dengan kompleksitas dan waktu pelatihan yang jauh lebih rendah. GRU akan lebih unggul jika ada pola temporal yang kuat dan signifikan dalam data yang tidak dapat ditangkap oleh model statis.

### 4.4.2 Perbandingan Kinerja

- **Metode Acuan (*Random Forest*)**:
  - $R^2$ (rata-rata cross-validation): 0.9537
  - RMSE: 3.6259
- **Metode Kembangan (GRU)**:
  - $R^2$: -0.0025
  - RMSE: 17.1328

Sama seperti perbandingan dengan LSTM, model Random Forest terbukti jauh lebih superior daripada GRU. Kesenjangan kinerja yang sangat besar antara $R^2 = 0.9537$ (RF) dan $R^2 = -0.0025$ (GRU) memperkuat kesimpulan bahwa pendekatan regresi tabular

adalah strategi pemodelan yang tepat untuk studi kasus ini, sedangkan pendekatan sekuensial dengan look_back pendek tidak berhasil menangkap dinamika sistem yang relevan.

#### 4.4.3 Perbandingan Kecepatan Proses

- **Waktu Pelatihan**:
  - Random Forest (Final, cross-validated): 55.3496 detik
  - GRU: 66.6013 detik
- **Waktu Prediksi**:
  - Random Forest: 0.0170 detik
  - GRU: 0.6890 detik

Perbandingan kecepatan proses menunjukkan efisiensi tinggi dari model Random Forest baik dalam pelatihan maupun prediksi. Waktu pelatihan Random Forest (55.35 detik) lebih cepat daripada GRU (66.60 detik). Kesenjangan efisiensi paling signifikan terlihat pada waktu prediksi, di mana Random Forest (0.0170 detik) jauh lebih cepat daripada GRU (0.6890 detik), menjadikannya pilihan superior untuk aplikasi latensi rendah.

# BAB V

# PENUTUP

## 5.1. Simpulan

Berdasarkan analisis komparatif yang telah dilakukan terhadap empat model *machine learning* untuk memprediksi keluaran daya listrik dari Pembangkit Listrik Siklus Gabungan (CCPP), dapat ditarik beberapa kesimpulan utama sebagai berikut:

1. Pendekatan Regresi Tabular Lebih Unggul: Model yang memproses data sebagai tabel statis, yaitu Random Forest dan ANN, menghasilkan performa yang jauh lebih baik daripada model berbasis sekuensial (LSTM dan GRU). Random Forest menjadi model

terbaik dengan $R^2$ = 0.9537 dan RMSE = 3.6259 MW, kemudian oleh ANN dengan $R^2$ = 0.9115 dan RMSE = 5.3487 MW.

2. Model Sekuensial Tidak Efektif: Metode kembangan berbasis RNN (LSTM dan GRU) memperlihatkan hasil yang tidak memuaskan. Hal ini terlihat dari nilai $R^2$ yang negatif dan RMSE yang sangat tinggi (di atas 17 MW). Temuan ini menunjukkan bahwa informasi dari satu jam sebelumnya (look_back=1) tidak cukup kuat untuk memprediksi keluaran daya saat ini, sehingga pendekatan ini tidak berhasil memodelkan hubungan kompleks dalam sistem CCPP.
3. Keunggulan dalam Kecepatan Proses: Model Random Forest terbukti paling efisien. Waktu pelatihannya adalah yang tercepat (55.35 detik), dan waktu prediksinya (0.0170 detik) jauh mengungguli semua model lain yang diuji.
4. Sesuaikan Model dengan Data: Penelitian ini membuktikan sebuah prinsip dasar dalam sains data, yaitu pemilihan model harus disesuaikan dengan sifat asli dari data. Untuk dataset CCPP ini, di mana hubungan antar variabel terjadi pada waktu yang sama (instan), model untuk data tabular adalah pilihan yang paling tepat.

### 5.2. Saran

Beberapa hal dapat dieksplorasi untuk meningkatkan pemahaman dan kinerja model. Kinerja model sekuensial (LSTM/GRU) yang kurang optimal dapat diuji lebih lanjut, misalnya dengan menggunakan periode historis (look_back) yang lebih panjang untuk melihat apakah ada pola data dari waktu ke waktu yang bisa lebih optimal. Di sisi lain, untuk meningkatkan hasil dari pendekatan tabular yang sudah terbukti unggul, dapat diuji algoritma gradient boosting seperti XGBoost atau LightGBM yang dikenal memiliki performa tinggi. Sebagai alternatif yang lebih komprehensif, dapat pula dikembangkan sebuah model hibrida yang menggabungkan input data instan dan historis sekaligus, yang berpotensi menghasilkan model paling akurat dengan memanfaatkan keunggulan dari kedua pendekatan.

---

**DAFTAR PUSTAKA**


- Data: Kaya, H., Tüfekci, P., & Gürgen, F. S. (2012). *Combined Cycle Power Plant Data Set*. UCI Machine Learning Repository. Diakses dari: https://archive.ics.uci.edu/dataset/294/combined+cycle+power+plant
- Alsisi, M. (2023). *Prediction of the output power of a combined cycle*. Kaggle. Diakses dari: https://www.kaggle.com/code/mohamedalsisi/prediction-of-the-output-power-of-a-combined-cycle
- Karataş, İ. (2021). *Regression for Combined Cycle Power Plant*. Kaggle. Diakses dari: https://www.kaggle.com/code/ibrahimkaratas/regression-for-combined-cycle-power-plant
- Breiman, L. (2001). Random Forests. *Machine Learning, 45*(1)
- Ahmad, T., Chen, H., Shah, S. A. A., & Zhang, L. (2020). A review on renewable energy forecasting using artificial neural network. *Sustainable Energy, Grids and Networks, 22*.
- Hornik, K., Stinchcombe, M., & White, H. (1989). Multilayer feedforward networks are universal approximators. *Neural Networks, 2*(5), p. 359.
- Chung, J., Gulcehre, C., Cho, K., & Bengio, Y. (2014). *Empirical Evaluation of Gated Recurrent Neural Networks on Sequence Modeling*.
- Lu, S., Zhai, J., & Wang, Y. (2019). *Short-term Load Forecasting of Power System Based on Gated Recurrent Unit*.
- Cho, K., Van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., & Bengio, Y. (2014). *Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation*.
- Hochreiter, S., & Schmidhuber, J. (1997). *Long Short-Term Memory*.


---

**KERJASAMA**

| REGU 211 | TUGAS |
|---|---|

| | |
|---|---|
| Yusuf Lamuri (13321050) | Membuat laporan |
| Kevin Kristian Silaen(13323036) | Mengembangkan metode acuan dan penyusunan laporan |
| Rio Haris Ewaldo Bukit (13323050) | Membuat metode kembangan |
| Zahran Khairan Azmi(13323092) | Membuat laporan |

**LAMPIRAN**

**Lampiran A: Hasil Metode Acuan (ANN)**

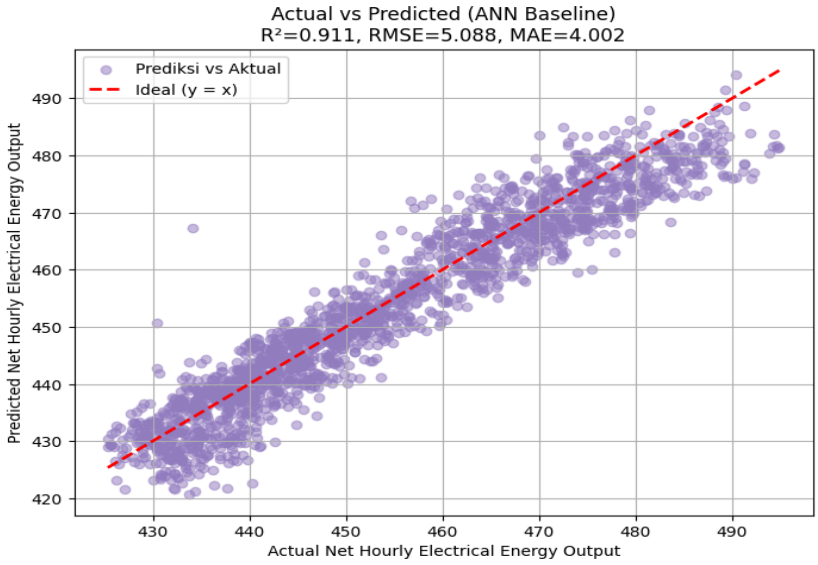


**Gambar L.1** Grafik sebar (*scatter plot*)

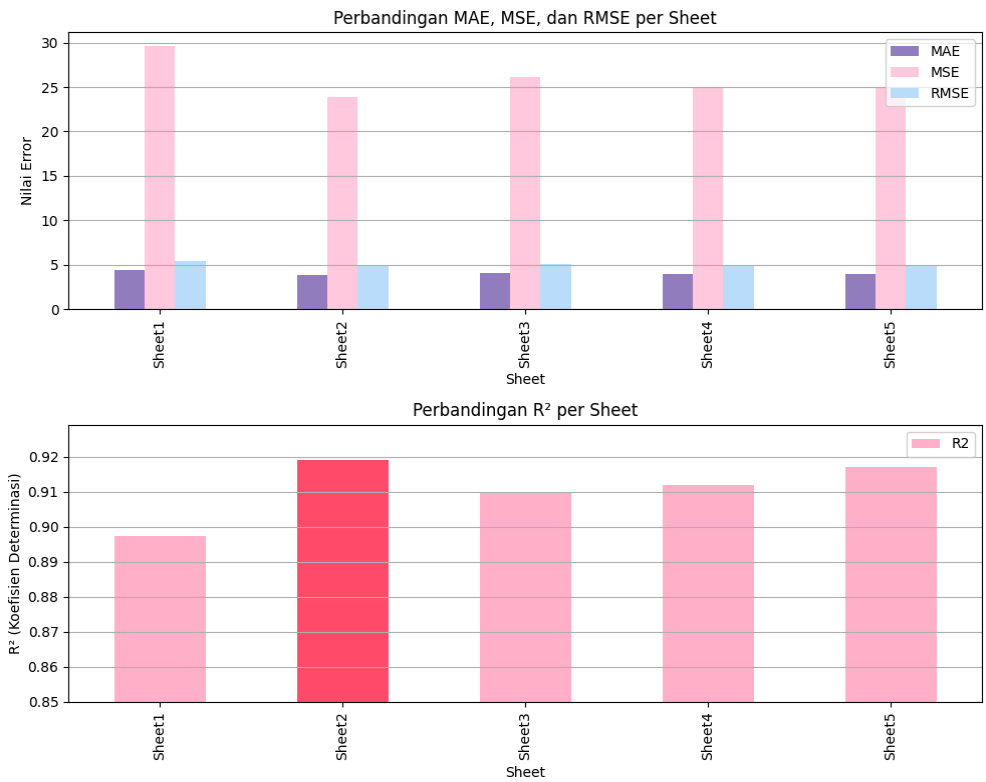


**Gambar L.2** Grafik batang yang menyajikan perbandingan metrik evaluasi

## Lampiran B: Hasil Metode Acuan (*Random Forest*)

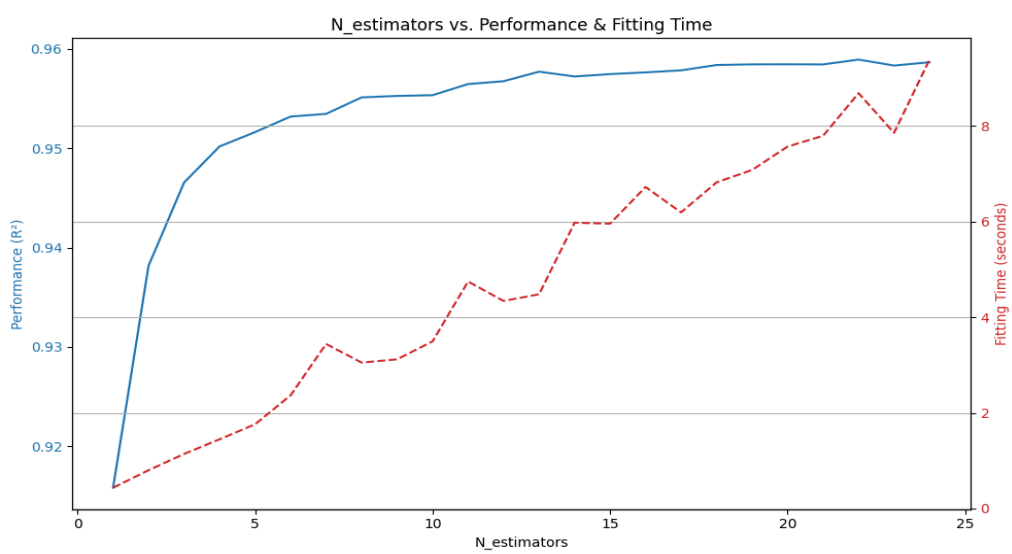


**Gambar L.3** Grafik analisis *hyperparameter n_estimators*.

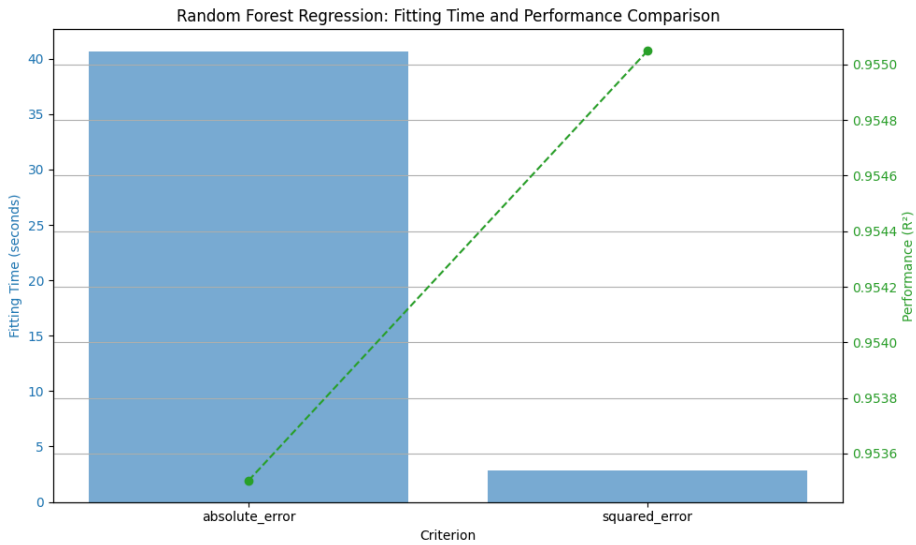


**Gambar L.4** Grafik batang yang membandingkan performa pemisahan absolute_error dan squared_error.

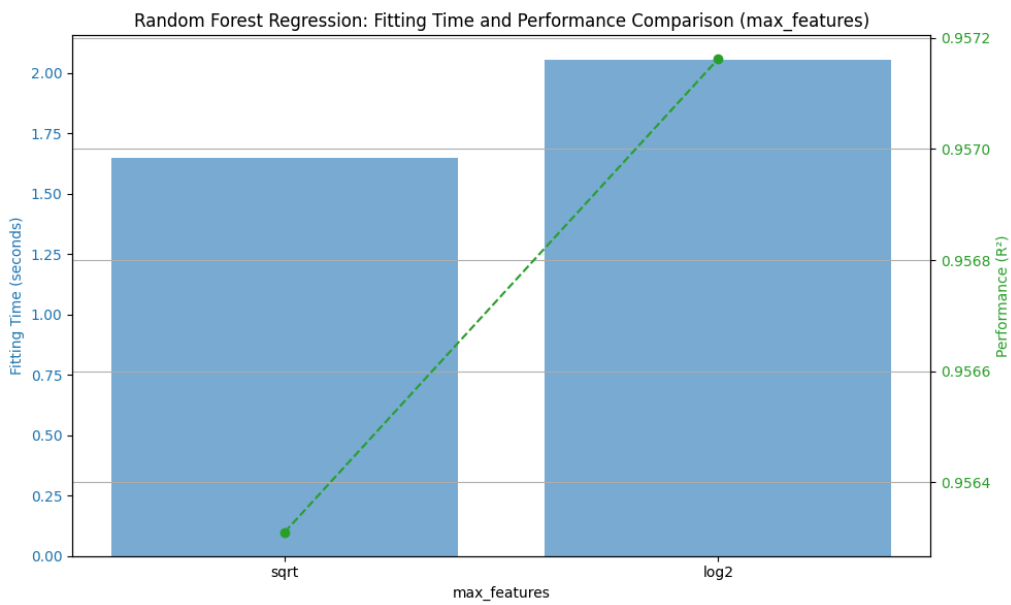


**Gambar L.5** Grafik batang yang membandingkan performa dan waktu komputasi untuk parameter `max_features` yang berbeda.

## Lampiran C: Hasil Metode Kembangan (LSTM & GRU)

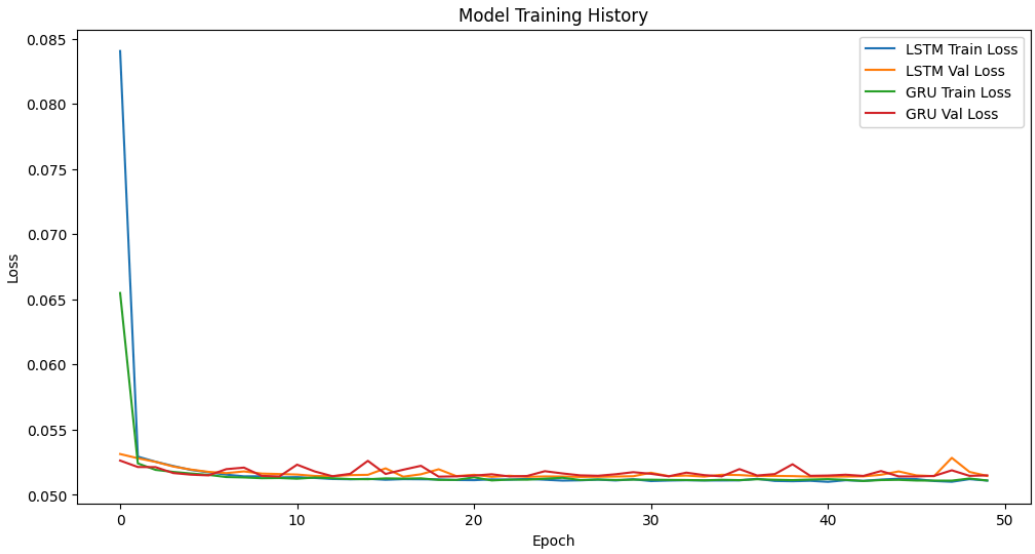


**Gambar L.6** Grafik riwayat pelatihan (*training history*)

## Lampiran D: Visualisasi Eksplorasi Data

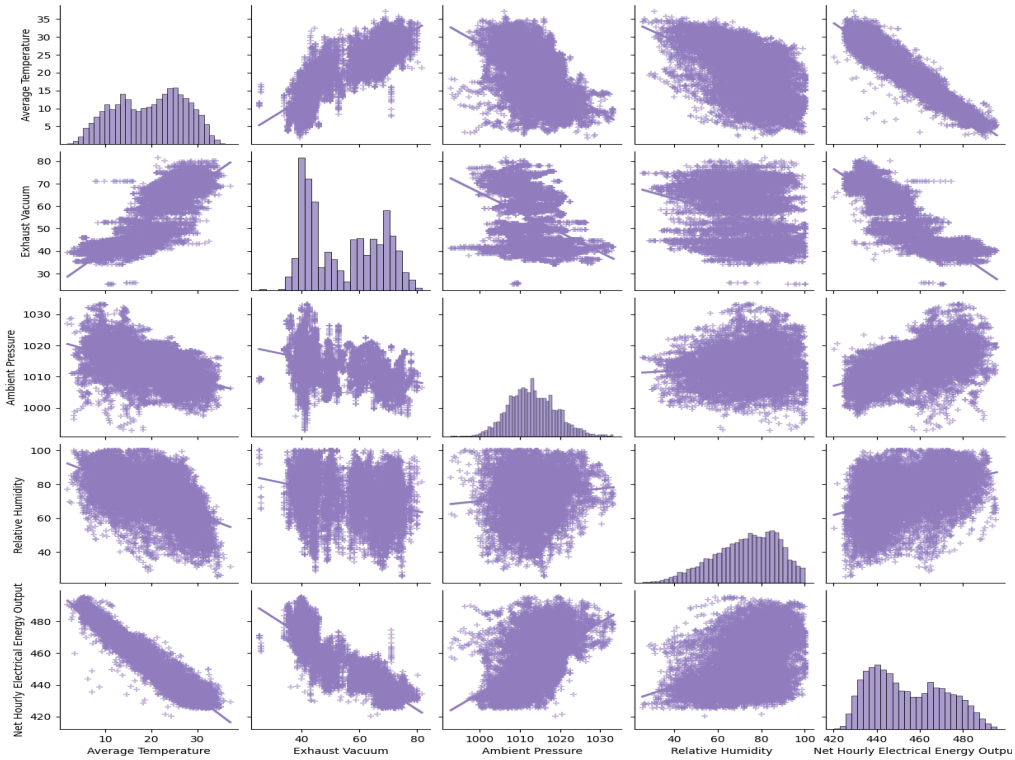


**Gambar L.7** Grafik *pairplot*

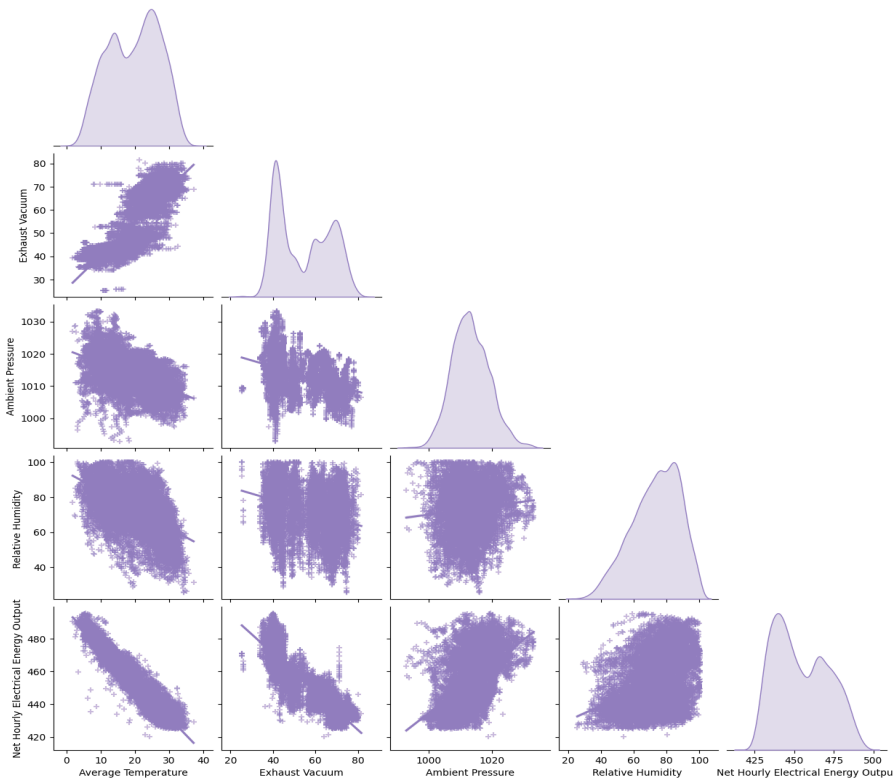


**Gambar L.8** Grafik *corner plot*